INF479 • FOTOGRAFÍA COMPUTACIONAL • ANÁLISIS DE ARTÍCULO

Making Fisher Work: Train-Time Compression for 3D Gaussian Splatting

P G Arun Madhav · Chandra Sekhar Seelamantula

Department of Electrical Engineering, Indian Institute of Science, Bangalore

IEEE International Conference on Image Processing (ICIP), 2026 · DOI: 10.1109/ICIP61757.2026.11630029

Presenta: **Francisco Alfaro Medina** · Universidad Técnica Federico Santa María

PROBLEMA Y OBJETIVO

3D-GS ocupa demasiado: el objetivo es comprimir al entrenar

PROBLEMA

Una escena puede requerir **millones de gaussianas**, con **59 parámetros** cada una. Los armónicos esféricos concentran más del **80 %** del almacenamiento.

→

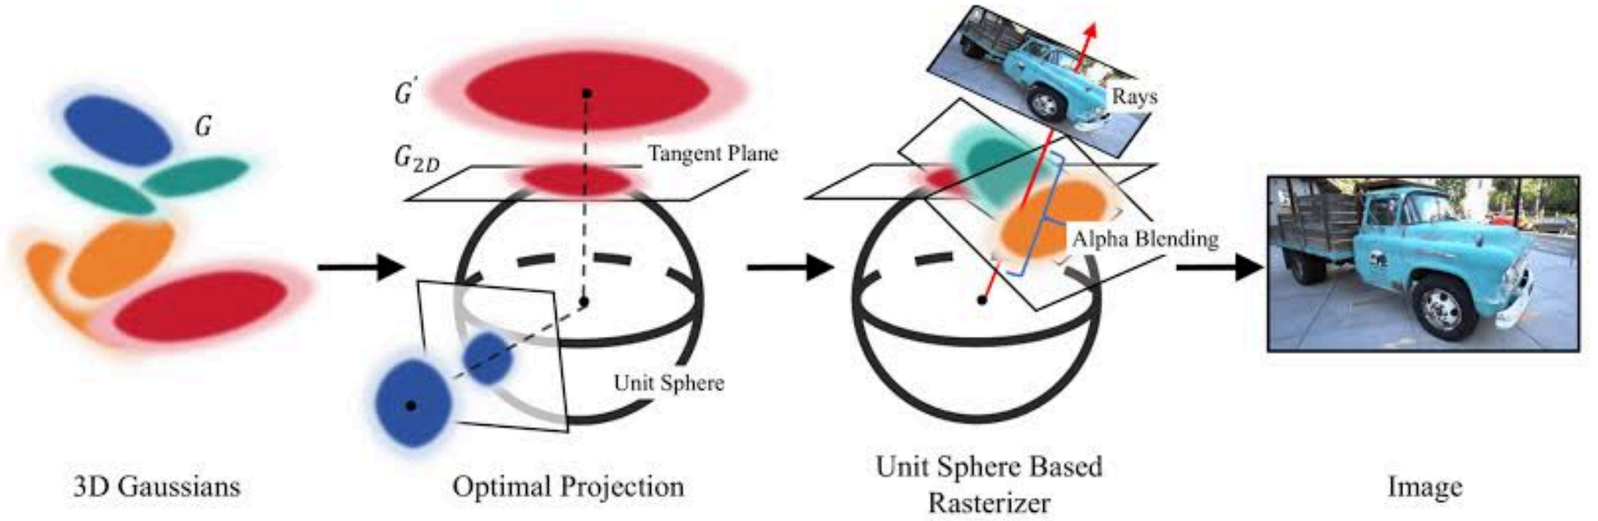
BRECHA

La poda y la cuantización suelen llegar **después del entrenamiento**, cuando la redundancia ya se acumuló.

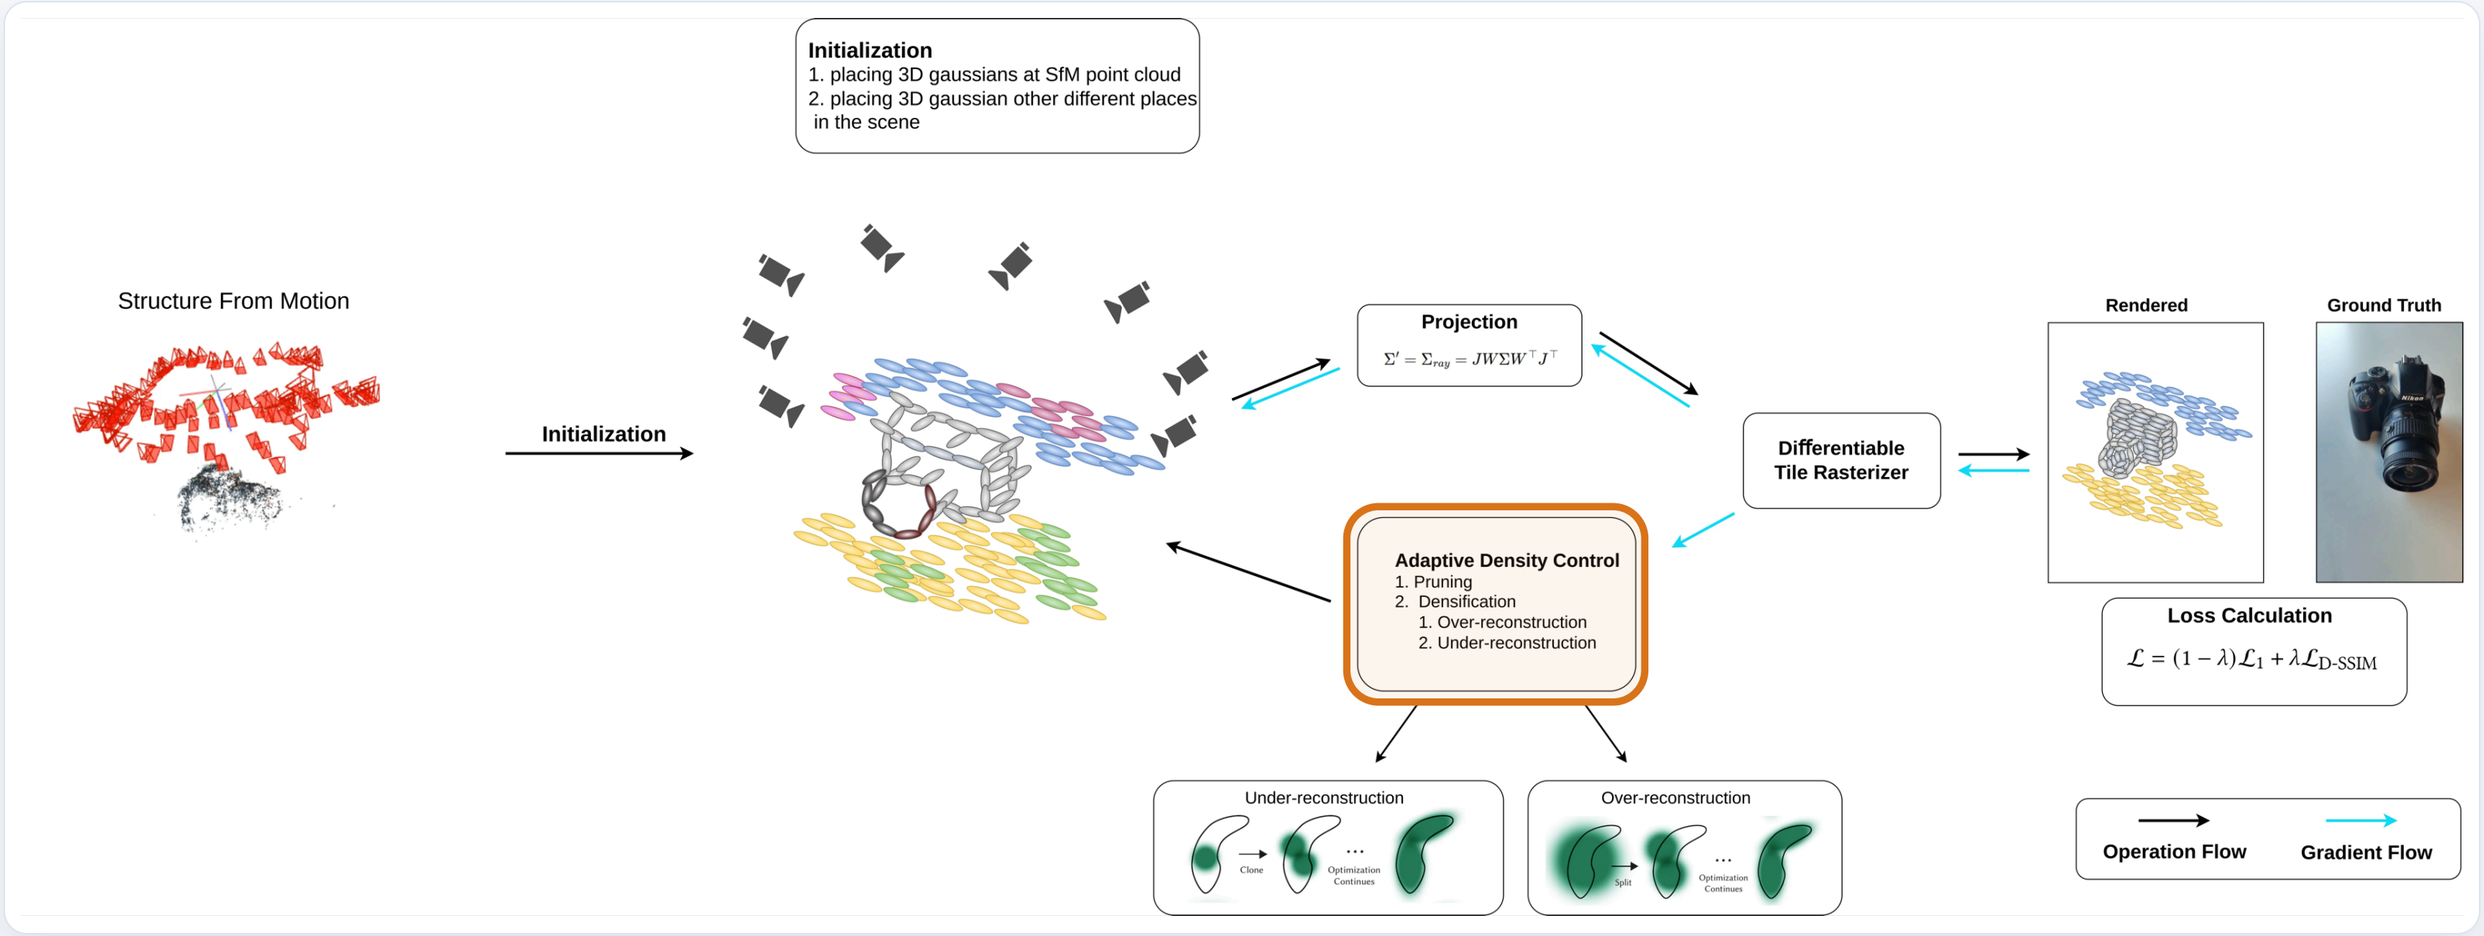
→

OBJETIVO DEL ARTÍCULO

Guiar la compresión **mientras se optimiza**: poda sensible a Fisher y cuantización CAQ durante el entrenamiento.



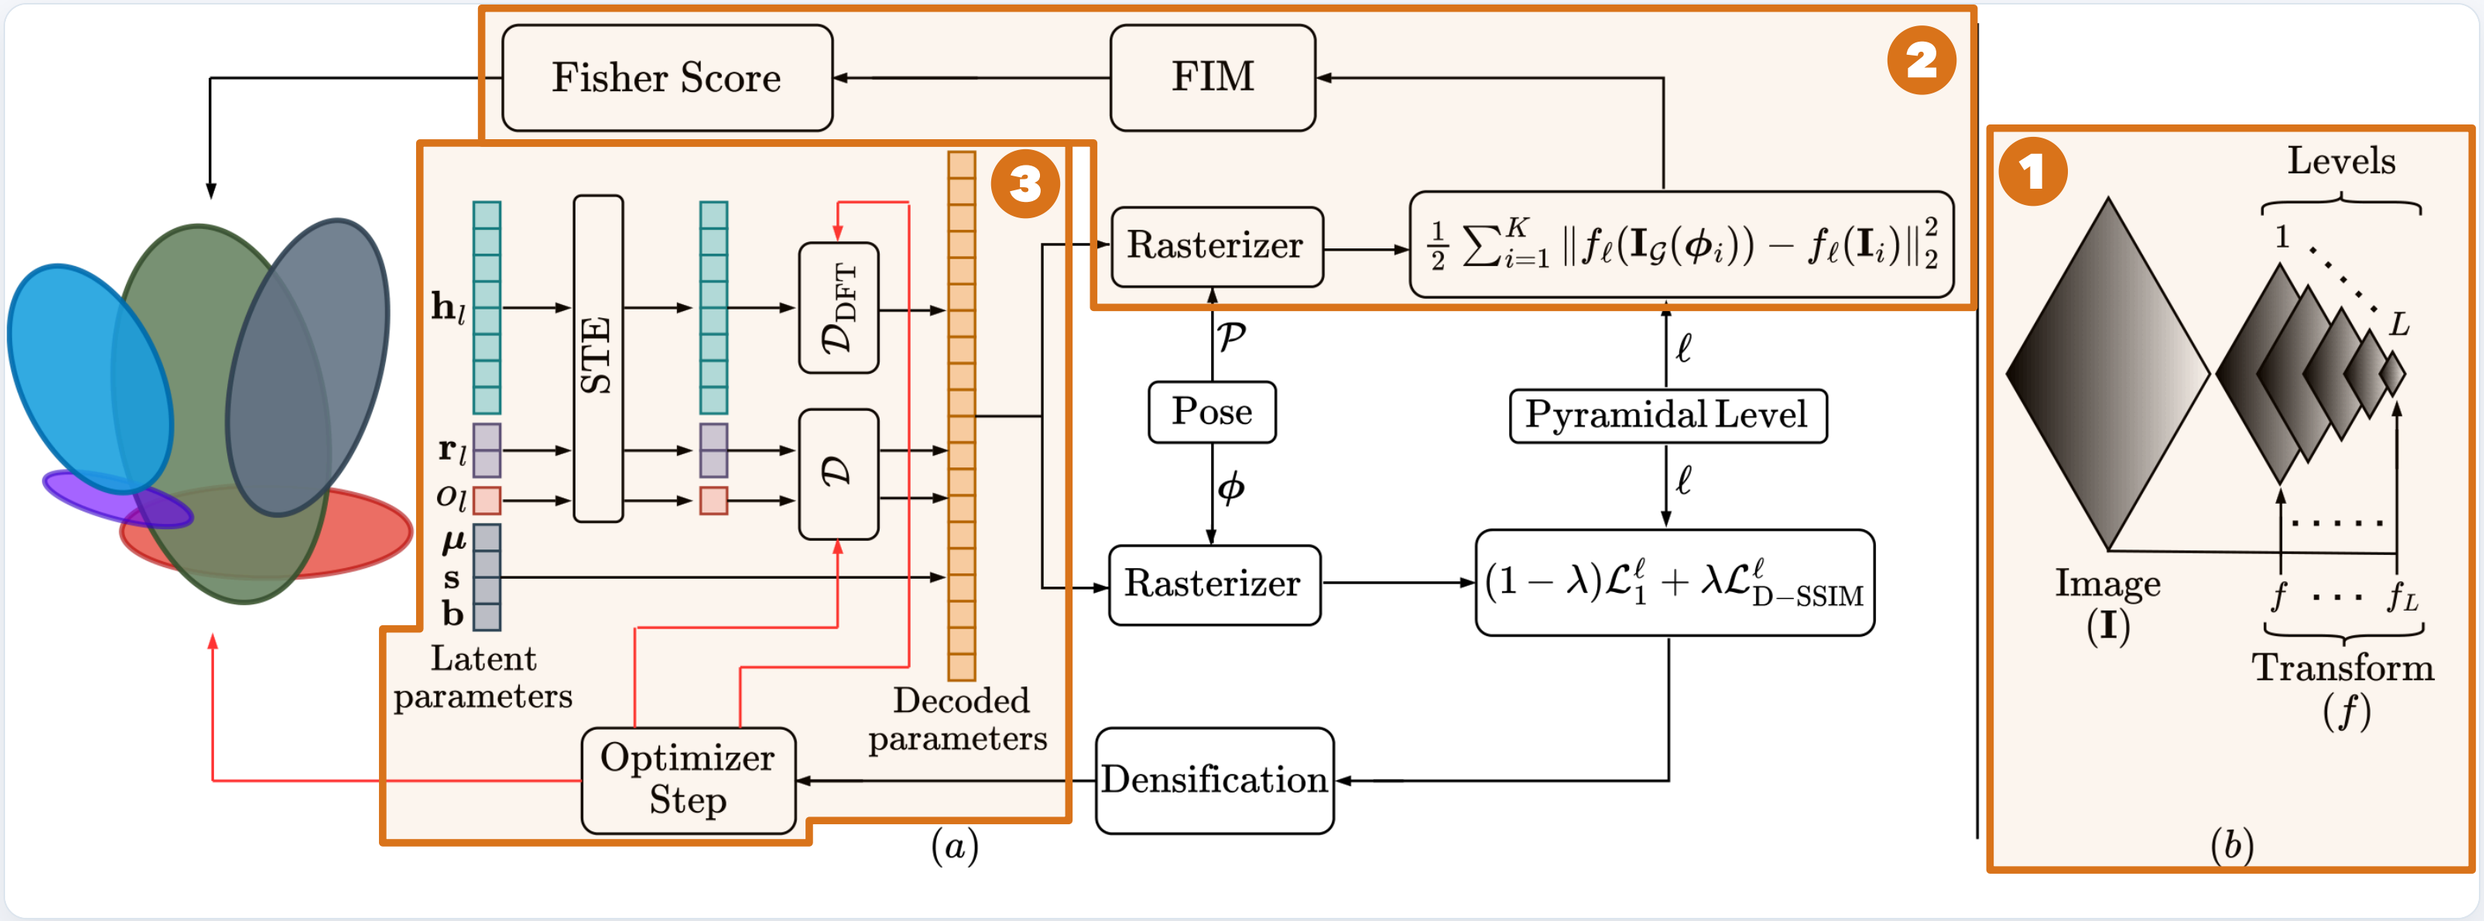
El pipeline de 3D-GS optimiza, densifica y poda



La poda se hará en la parte remarcada: **Adaptive Density Control**.

EL LAZO DEL ARTÍCULO · FIG. 2

Todo ocurre en un único lazo de entrenamiento



Fuente: artículo, Fig. 2.

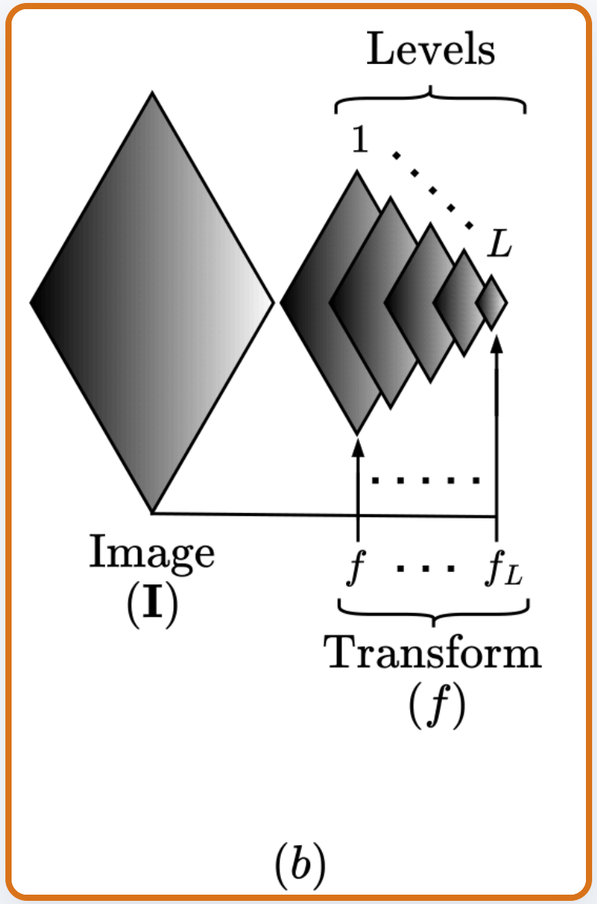
1 **Pirámide:** de grueso a fino

2 **Fisher:** poda al entrenar

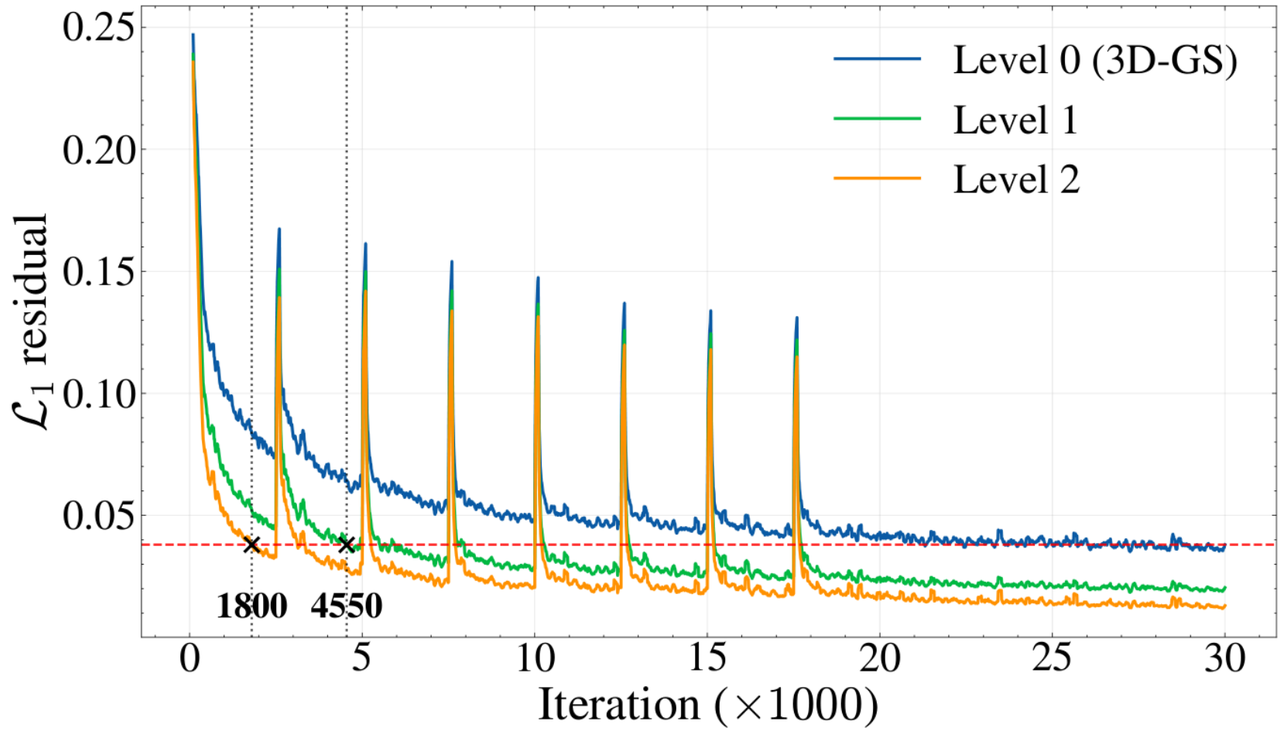
3 **CAQ:** cuantización por correlación

PASO 1 · PIRÁMIDE · FIG. 2(B) Y FIG. 3

De grueso a fino: residual bajo muy temprano



Fuente: artículo, Fig. 2(b).



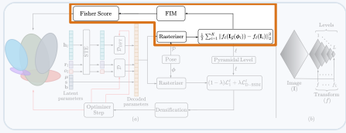
Tanks&Temples; línea roja: 3D-GS convergido. Fuente: artículo, Fig. 3.

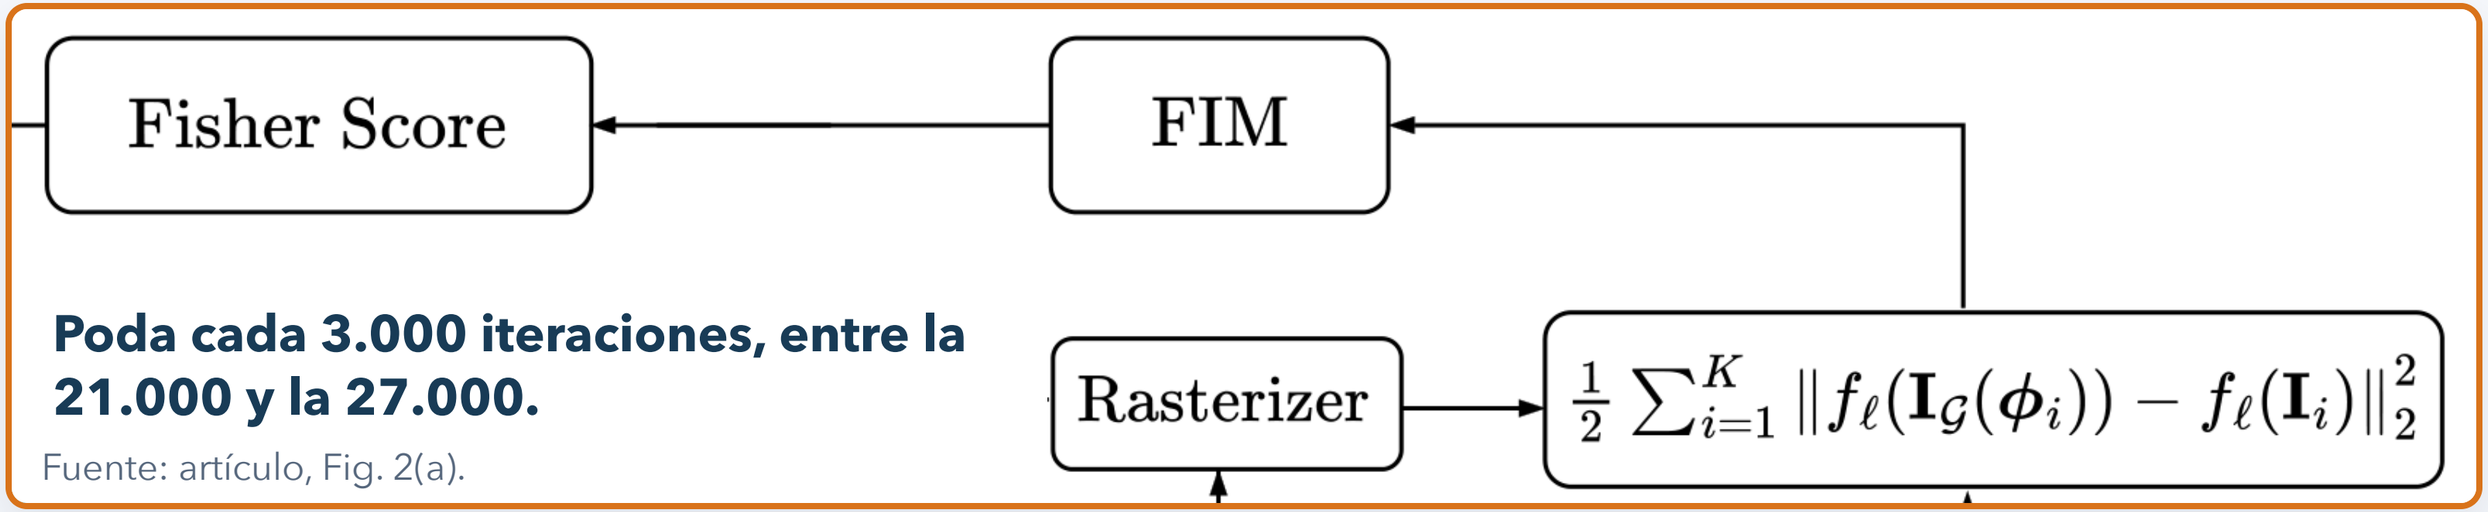
Se entrena primero con imágenes **suavizadas y reducidas**; el detalle fino entra después.

Los niveles 2 y 1 bajan del residual de un 3D-GS convergido en las iteraciones **1.800** y **4.550**.

PASO 2 · FISHER Y PODA · FIG. 2(A) Y FIG. 4

Con residual bajo, el Hessiano da un puntaje por gaussiana





Poda cada 3.000 iteraciones, entre la 21.000 y la 27.000.

Fuente: artículo, Fig. 2(a).

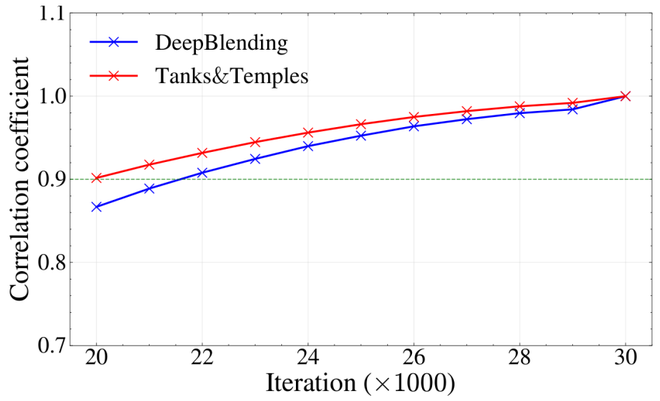
Fisher: cuánto cambia la imagen al perturbar los parámetros

$$\nabla^2_{\mathcal{G}}\mathcal{L}_2 \approx \sum_{i=1}^{K} \mathbf{J}_{f_\ell} \nabla_{\mathcal{G}} \mathbf{I}_{\mathcal{G}}(\boldsymbol{\phi}_i)\, \nabla_{\mathcal{G}} \mathbf{I}_{\mathcal{G}}(\boldsymbol{\phi}_i)^\top \mathbf{J}_{f_\ell}^\top$$

Bloque de cada gaussiana → puntaje

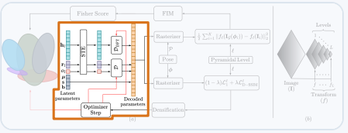
$$U_j = \log |\mathbf{H}_j|$$

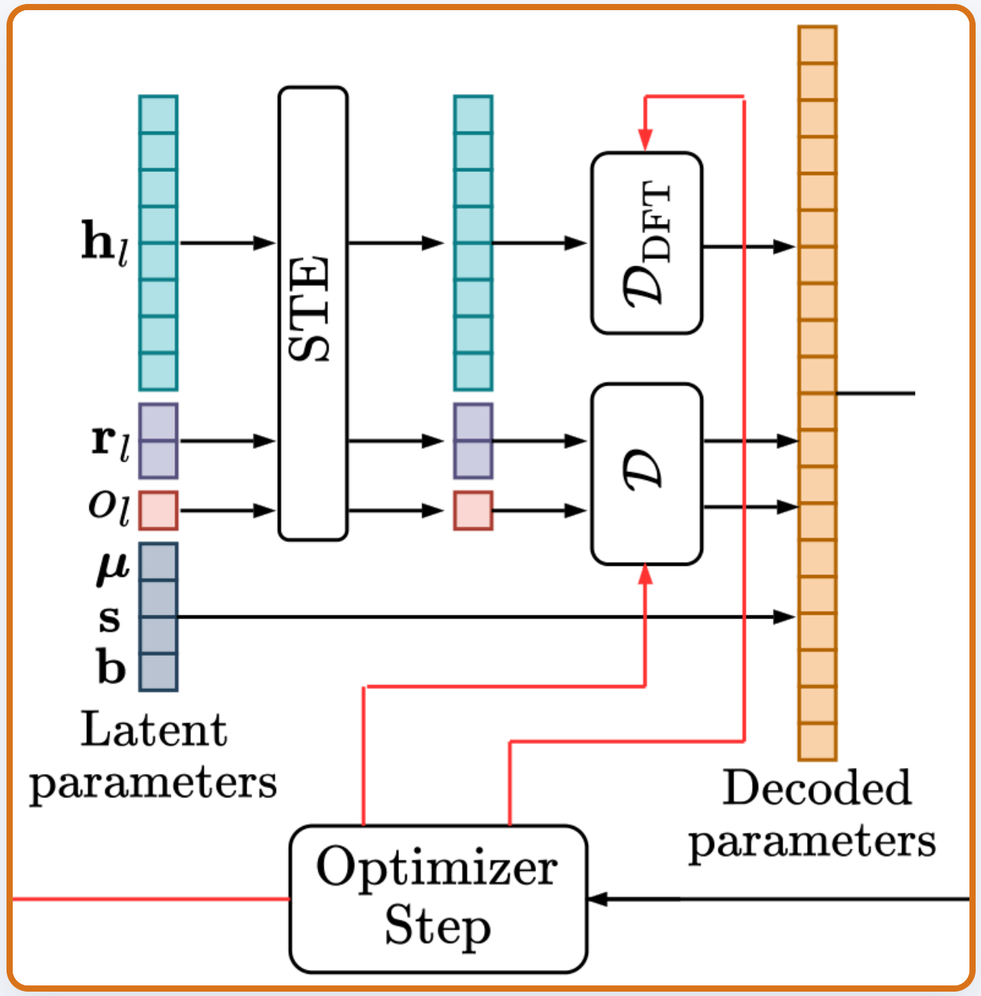
U_j bajo: la gaussiana se considera **redundante** y se poda.



Spearman. Fuente: artículo, Fig. 4.

CAQ cuantiza cada grupo según su correlación





Fuente: artículo, Fig. 2(a).

Rotación y opacidad $(\mathbf{r}_\ell, o_\ell)$: decorrelacionadas [5]. Latentes escalares y decodificador lineal $\mathcal{D}$.

Armónicos esféricos $(\mathbf{h}_\ell)$: fuerte correlación entre canales [16]. Decodificador basado en DFT, $\mathcal{D}_{\mathrm{DFT}}$ [17].

STE [18]: discretiza hacia adelante y conserva el gradiente hacia atrás.

$$\mathbf{h} = \mathcal{D}_{\mathrm{DFT}}\big(\mathrm{STE}(\mathbf{h}_\ell)\big), \quad \mathbf{r}, o = \mathcal{D}\big(\mathrm{STE}(\mathbf{r}_\ell, o_\ell)\big)$$

RESULTADOS · TABLAS 1 Y 2 DEL ARTÍCULO

≈95 % menos almacenamiento que 3D-GS, con calidad competitiva

Método	Mip-NeRF 360 [19]		Tanks&Temples [20]		Deep Blending [21]	
	PSNR↑	MB↓	PSNR↑	MB↓	PSNR↑	MB↓
3D-GS [1]	27,44	822,6	23,67	452,4	29,48	692,5
Compact [4]	26,95	**26,31**	23,33	**18,97**	29,71	**25,75**
EAGLES [5]	**27,07**	59,49	23,14	30,18	29,72	54,45
LightGaussian [6]	26,90	53,96	23,32	29,94	29,12	45,25
PUP [7]	26,67	74,65	22,72	43,37	28,85	69,98
Propuesto	**27,01**	**32,78**	**23,38**	**23,93**	**29,87**	**30,07**

Mejor de la columna, según el artículo; 3D-GS queda fuera del ranking.

≈95 %

menos que 3D-GS (promedio)

Ablación en *bonsai*: CAQ reduce los bytes por primitiva (294,55 → 44,22 MB); PPT y las podas reducen las primitivas (0,98 → 0,33 M).

Conclusión: la poda basada en Fisher ya funciona durante el entrenamiento

APORTA

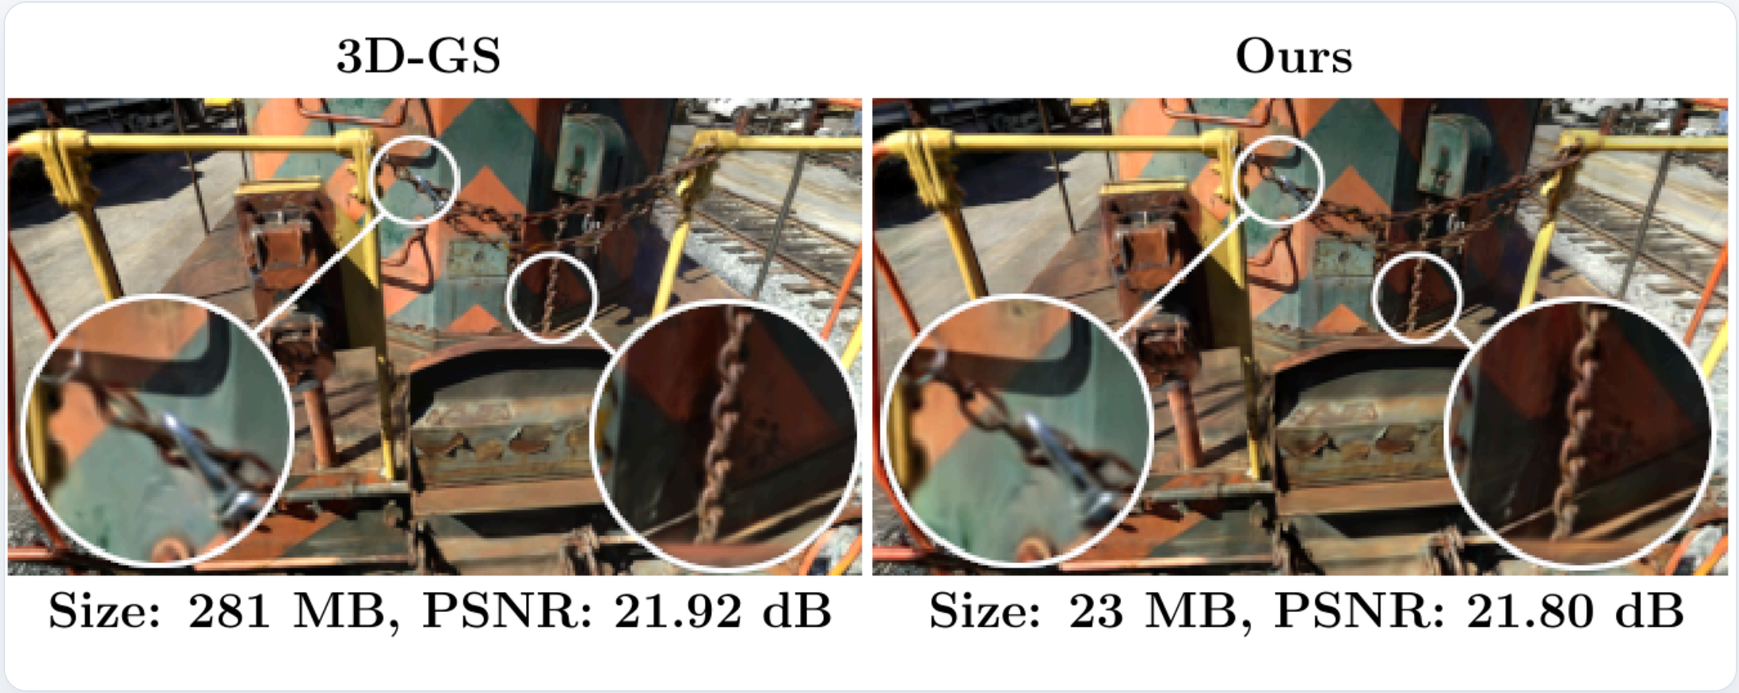
Poda basada en Fisher **en tiempo de entrenamiento**.

LOGRA

≈95 % menos almacenamiento que 3D-GS.

EXTENSIÓN DE LOS AUTORES

Cronogramas adaptativos y otras estrategias de cuantización.



Escena *train*, Tanks&Temples. Fuente: artículo, Fig. 1.

¿Preguntas?

Muchas gracias.

Francisco Alfaro Medina
UTFSM

Tabla 1 completa

Método	Mip-NeRF 360 [19]				Tanks&Temples [20]				Deep Blending [21]			
	PSNR↑	SSIM↑	LPIPS↓	MB↓	PSNR↑	SSIM↑	LPIPS↓	MB↓	PSNR↑	SSIM↑	LPIPS↓	MB↓
3D-GS [1]	27,44	0,813	0,218	822,6	23,67	0,844	0,179	452,4	29,48	0,900	0,246	692,5
Compact [4]	26,95	0,797	0,244	**26,31**	23,33	0,831	0,202	**18,97**	29,71	0,901	0,257	**25,75**
EAGLES [5]	**27,07**	0,801	0,240	59,49	23,14	0,833	0,203	30,18	29,72	0,906	0,249	54,45
LightGaussian [6]	26,90	0,800	0,240	53,96	23,32	0,829	0,204	29,94	29,12	0,895	0,262	45,25
PUP [7]	26,67	0,786	0,271	74,65	22,72	0,801	0,244	43,37	28,85	0,881	0,301	69,98
Propuesto	**27,01**	**0,801**	**0,239**	**32,78**	**23,38**	**0,837**	**0,202**	**23,93**	**29,87**	**0,912**	**0,248**	**30,07**

Mejor Segundo Marcado del artículo; 3D-GS queda fuera del ranking.

Tabla 2 completa: ablación en *bonsai*

Configuración	PSNR↑	SSIM↑	LPIPS↓	Primitivas↓	MB↓
3D-GS	32,25	0,946	0,181	1,25 M	294,55
+ CAQ	31,36	0,937	0,216	0,98 M	44,22
+ PPT	31,35	0,936	0,216	0,80 M	36,82
+ PP	30,94	0,933	0,219	0,66 M	30,88
+ IP	30,91	0,932	0,224	0,33 M	15,24
Propuesto	**30,92**	**0,932**	**0,224**	**0,33 M**	**15,28**

Tabla 2 del artículo, escena bonsai. CAQ: cuantización consciente de la correlación. PPT: entrenamiento piramidal progresivo. PP: poda piramidal. IP: poda iterativa.

Referencias

Artículo. P. G. Arun Madhav y C. S. Seelamantula, «Making Fisher Work: Train-Time Compression for 3D Gaussian Splatting», IEEE ICIP, 2026.

[1] Kerbl et al., «3D Gaussian Splatting for Real-Time Radiance Field Rendering», *ACM TOG*, 2023.

[4] Lee et al., «Compact 3D Gaussian Representation for Radiance Field», arXiv:2311.13681, 2023.

[5] Girish et al., «EAGLES», ECCV, 2024.

[6] Fan et al., «LightGaussian», NeurIPS, 2024.

[7] Hanson et al., «PUP 3D-GS», arXiv:2406.10219, 2024.

[16] Seeley, «Spherical Harmonics», *Amer. Math. Monthly*, 1966.

[17] Moczulski et al., «ACDC: A Structured Efficient Linear Layer», 2016.

[18] Huh et al., «Straightening Out the Straight-Through Estimator», ICML, 2023.

[19] Barron et al., «Mip-NeRF 360», CVPR, 2022.

[20] Knapitsch et al., «Tanks and Temples», *ACM TOG*, 2017.

[21] Hedman et al., «Deep Blending for Free-Viewpoint Image-Based Rendering», *ACM TOG*, 2018.