
SAT-E · Sistema de Alerta Temprana Estudiantil

Consolidar datos institucionales para intervenir a tiempo

Descripción general del sistema: alertas, modelos y resultados

Marzo 2026

Francisco Alfaro Medina
Universidad Técnica Federico Santa María

El problema: la deserción en primer año

1 de cada 4

estudiantes no completa
su primer año universitario

Ventana crítica. El primer semestre —y muy especialmente las primeras semanas— define la trayectoria del estudiante.

- **Magnitud** — entre **25 % y 30 %** abandona en primer año, una de las tasas más altas de la OCDE (SIES / Mineduc).
- **Perfil de riesgo** (CRUCH) — primera generación universitaria, regiones alejadas, colegios municipales.
- **Costo sistémico** — el estudiante abandona **con deuda** (CAE / FIES) y **sin título**; la institución pierde matrícula.
- La consecuencia práctica: cuando la deserción se detecta en las actas de fin de año, ya es tarde para hacer algo.

Contexto institucional: UTFSM

Dónde se aplica

3 campus — Casa Central, San Joaquín, Vitacura
2 sedes — Viña del Mar y Concepción

De dónde vienen los datos

- SIGA** — sistema de gestión académica
- AULA** — plataforma docente (Moodle)
- Datos Mineduc** — antecedentes de admisión

Categorías de carrera modeladas

Sigla	Programa
ING6	Ingeniería Civil (6 años)
ING5	Ingeniería de Ejecución (5 años)
TU	Técnico Universitario
IBT	Ingeniería de Base Tecnológica

i **Por qué segmentar**

Se modela **por categoría de carrera**, no con un único modelo global: los perfiles de ingreso, las mallas y los ramos críticos son muy distintos entre un ING6 y un TU.



Qué es el SAT-E

Una herramienta de priorización, no un sistema de decisión

Definición, objetivo y principio

Definición formal

El SAT-E consolida datos de distintas fuentes institucionales en **modelos predictivos** que generan alertas actualizadas según la información disponible en cada momento del ciclo académico.

Objetivo central

Identificar estudiantes en riesgo de **reprobación de asignatura crítica** o de **deserción** antes de que el daño sea irreversible, para activar intervenciones dirigidas desde los equipos de acompañamiento y jefes de carrera.

Principio clave

No es vigilancia, es apoyo. El sistema **no toma decisiones automáticas** sobre ningún estudiante: es una herramienta de priorización para que los equipos humanos intervengan con criterio.

La salida del sistema no es un veredicto: es una **lista priorizada** que le dice a un equipo con tiempo limitado a quién conviene llamar primero.

La ventana crítica




La mayor probabilidad de deserción ocurre en los **primeros dos semestres**. Las alertas se emiten dentro de esa ventana: Alerta 0 antes del inicio, Alertas 1 y 2 durante el primer semestre.

Las alertas

Tres momentos, tres conjuntos de datos, dos preguntas

Las tres alertas



Alerta 0 · admisión — solo datos Mineduc, **sin ningún dato universitario** todavía.

Alerta 1 · semana ~5 — incorpora asistencia, CIAC y la **nota del certamen 1**: el primer dato universitario real.

Alerta 2 · fin de 1.^{er} semestre — incorpora ramos aprobados y reprobados; **cambia la pregunta.**

Ramos críticos: dos criterios

Diagrama 1 — Ruta crítica por tasa de reprobación:
Se tiene historia de los ramos






Diagrama 2 — Ruta crítica por apertura de ramos
Útil nuevas carreras (sin historia)



! El ramo crítico dejó de ser único

En ING5 / ING6 el ramo crítico era **MATo21**. En las nuevas mallas ese ramo se separa en **MATo6o** (Álgebra Lineal) y **MATo7o** (Cálculo), redistribuyendo el peso: el ramo crítico **ya no es único ni predecible**, se calcula por malla.

Cómo se calcula la nota crítica C1




- Se toman **todas las cátedras tipo C1** con nota válida; se descartan los nulos.
- **Caso 1 — tiene al menos un ramo MAT:** C1 es el **mínimo** entre sus notas MAT, y ese ramo pasa a ser el crítico.
- **Caso 2 — sin ramos MAT:** C1 es el **promedio** de todas sus notas C1.
- La sigla cuenta como MAT si empieza con **MAT**, pero se **excluyen** los sufijos **Y**, **L** y **T** (laboratorios y talleres).

💡 Por qué el mínimo

Tomar el **mínimo** y no el promedio es una decisión deliberada: en matemáticas, un solo ramo hundido es mejor predictor que un promedio que lo diluye.

Cómo se construye Datos integrados, pipelines reproducibles, modelos por cohorte

Data warehouse: una sola fuente de verdad



¿Qué es un Data Warehouse?

Un repositorio centralizado que almacena grandes volúmenes de datos estructurados de múltiples fuentes, organizado **para análisis**, no para transacciones.

```
silver_undergraduate.new_students_features
— antecedentes de ingreso (mdt)
```

```
registration.aux_student_grades — notas
```

```
studentaid.aux_attendance — asistencia (ciac)
```


Kedro: de notebook a pipeline productivo

Kedro es un framework de Python que convierte pipelines de data science en código **estructurado, reproducible y productivo**.

Estructurado — nodos y catálogos de datos explícitos, en vez de celdas con estado oculto.

Reproducible — el mismo pipeline corre igual en el notebook del analista y en el servidor.

Productivo — se puede reejecutar por partes cuando llegan datos nuevos.



Grafo de dependencias del pipeline: partición de datos, entrenamiento y registro de parámetros de experimento.

De la probabilidad al grupo de riesgo

Los modelos

- **XGBoost** — árboles de decisión ensamblados; clasifica según presencia o ausencia de alerta. Es el modelo en uso.
- **Red neuronal** — capas de neuronas interconectadas; explorada como alternativa.

El paso a categorías

La probabilidad estimada se convierte en un **grupo de riesgo** aplicando umbrales según criterios operacionales:

Sin Riesgo • Riesgo Bajo • Riesgo Medio • Riesgo Alto

⚠ Advertencia metodológica

Los grupos no son comparables entre años. La distribución de probabilidades varía entre cohortes y cada modelo se entrena con datos distintos, así que un “Riesgo Alto” de 2025 y uno de 2026 no significan lo mismo.

ℹ Cómo leer la importancia

La importancia de variables no es causalidad. Se interpreta según la utilidad de cada variable para generar divisiones (*splits*) dentro del modelo, no como una relación causal directa.

Cómo entrenamos: esquema expansivo

	2023	2024	2025	2026
M23	Entrena cohort 2023	Predice 2024	Predice 2025	Predice 2026
M24	Entrena cohort 2023	Entrena cohort 2024	Predice 2025	Predice 2026
M25	Entrena cohort 2023	Entrena cohort 2024	Entrena cohort 2025	Predice 2026

Ventaja

Entrenar con los datos más recientes es más representativo del contexto actual: captura cambios en el perfil de ingreso y en las políticas institucionales.


Desventaja

Cada modelo se entrena con datos distintos, así que **M23, M24 y M25 no son directamente comparables**: una diferencia en métricas puede deberse al cambio en los datos, no a una mejora real.


Resultados

Qué pasa cuando entra el primer dato universitario


Alerta 0 vs Alerta 1 — cohorte 2025



- **Cómo leerla:** cada fila es el grupo de riesgo previo (Ao) y cada columna el actual (A1). La diagonal son los que mantienen su condición; a la izquierda bajan de riesgo, a la derecha suben.
- **El 70 %** de los estudiantes *sin riesgo* permanece en esa condición.
- En cambio, **Riesgo Medio y Riesgo Alto** presentan mucha más movilidad: el Riesgo Medio se reparte casi uniformemente entre las cuatro categorías (21,2 / 28,0 / 24,7 / 26,1).
- **Conclusión:** los grupos de menor riesgo tienden a mantenerse; los de mayor riesgo requieren seguimiento y apoyo focalizado.



Cohorte 2026: el problema de cobertura




50,5 %

de la cohorte tiene nota C1 disponible (2.575 de 5.100)

24 % / 23 %

cobertura de C1 en IBT y TU, contra 71 % en ING6

Alerta 0 vs Alerta 1 — cohorte 2026



Se repite el patrón de 2025: el 78,2 % de los *sin riesgo* se mantiene, mientras el Riesgo Medio sigue siendo el grupo más volátil (27,9 / 26,5 / 18,4 / 27,1).

El 40,8 % no cambia de grupo. De los que sí se mueven, **bajan más de los que suben:** 37,3 % baja de categoría y 21,9 % sube.

Qué variables pesan



Fila superior (Alerta 0, sin C1) — la importancia se reparte entre `math1_score`, `nem_score`, `language_score`, vulnerabilidad, dependencia del colegio y región. **Fila inferior (Alerta 1, con C1)** — `C1` domina y desplaza a todo lo demás.

Conclusiones

Dificultades

- **Obtener la nota crítica a tiempo** — depende del registro oportuno por parte de los profesores, y hoy solo la mitad de la cohorte la tiene cuando se calcula la Alerta 1.
- **Dependencia de C1** — cuando está disponible, concentra casi toda la importancia del modelo y desplaza al resto de las variables.
- **Definir los grupos de riesgo** — los umbrales son operacionales y no comparables entre cohortes: es un problema de formulación, no de ajuste.

Mejoras en curso

- **Análisis exploratorio más amigable para el negocio** — que jefes de carrera y equipos de acompañamiento puedan leer las alertas sin intermediación técnica.
- **Pipeline robusto** — poder ejecutar el sistema en cualquier momento del ciclo académico, no solo en fechas fijas.
- Trabajo asociado en **backtesting** y **monitoreo de data drift** para vigilar la degradación de los modelos.

El SAT-E ya funciona como herramienta de priorización. El cuello de botella hoy **no es el modelo**: es la **disponibilidad oportuna del dato** que lo alimenta.

Gracias

¿Preguntas?

SAT-E · Sistema de Alerta Temprana Estudiantil

Presentaciones relacionadas: SAT-E — backtesting · SAT-E — data drift

Francisco Alfaro Medina · Universidad Técnica Federico Santa María

<https://github.com/fralfaro/talks>