SAT-E: SISTEMA DE ALERTA TEMPRANA MULTINIVEL PARA LA DETECCIÓN DE RIESGO ACADÉMICO Y DESERCIÓN EN ESTUDIANTES DE PRIMER AÑO DE INGENIERÍA

Francisco Alfaro Medina, Universidad Técnica Federico Santa María, francisco.alfaro@usm.cl, ORCID: 0009-0003-7255-466X
Valeska Canales Pozo, Universidad Técnica Federico Santa María, valeska.canales@usm.cl, ORCID: 0009-0001-9690-9942
Patricio Olivares, Universidad Técnica Federico Santa María, patricio.olivaresr@usm.cl, ORCID: 0000-0003-1712-626X

RESUMEN

Este trabajo presenta **SAT-E**, el Sistema de Alerta Temprana Estudiantil desarrollado por la Dirección de Transformación Digital de la Universidad Técnica Federico Santa María para anticipar el riesgo académico y la deserción durante el primer año de pregrado. A diferencia de los enfoques de alerta única, emite tres alertas secuenciales sobre la misma cohorte: A0 en la matrícula, con antecedentes de admisión; A1 tras la primera evaluación de la asignatura crítica de matemática; y A2 al cierre del primer semestre, con el avance curricular efectivo. Cada alerta usa modelos de gradient boosting entrenados por tipo de carrera, y sus probabilidades se traducen a cuatro grupos de riesgo mediante una optimización de umbrales por evolución diferencial que impone tamaños operables para las unidades de acompañamiento. Implementado como un pipeline reproducible en Kedro, publica sus salidas en una tabla institucional que consumen los equipos de apoyo estudiantil. Entrenados con las cohortes 2023 a 2025 y aplicados a la cohorte 2026 (5.100 estudiantes, 81 programas), los modelos mejoran su desempeño en el conjunto de prueba a medida que crece la información disponible: AUC-ROC ponderado de 0,708 en A0, 0,853 en A1 y 0,870 en A2. El hallazgo principal es que la ganancia predictiva no proviene de modelos más complejos, sino de una sola variable de trayectoria observada oportunamente.

PALABRAS CLAVE: sistema de alerta temprana, deserción estudiantil, analítica del aprendizaje, aprendizaje automático, retención en ingeniería

INTRODUCCIÓN

La retención de primer año es uno de los indicadores más sensibles del sistema de educación superior chileno y, en particular, de las carreras de ingeniería, donde la exigencia de las asignaturas de ciencias básicas del primer semestre concentra una fracción sustantiva del abandono. El primer año opera como un filtro: la trayectoria de un estudiante que reprueba la asignatura crítica de matemática difiere de manera persistente de la de sus pares, y las decisiones de permanencia se toman en una ventana temporal breve. Esta observación es consistente con los modelos clásicos de abandono, que entienden la deserción como el resultado acumulado de un proceso de integración académica y social más que como un evento aislado (Tinto, 1975, 1993).

La consecuencia operativa es exigente: cualquier dispositivo de acompañamiento que se active después de conocidas las calificaciones finales llega tarde para una parte importante de los estudiantes a los que pretende apoyar. De ahí el interés por los sistemas de alerta temprana, uno

de los desarrollos más consolidados de la analítica del aprendizaje en educación superior (Siemens y Long, 2011; Baker e Inventado, 2014). Experiencias como *Course Signals* en Purdue (Arnold y Pistilli, 2012) o la iniciativa abierta de Jayaprakash et al. (2014) mostraron que es posible identificar estudiantes en riesgo con la información administrativa que la institución ya posee, y que el valor del sistema depende menos del modelo que de su acoplamiento con una respuesta institucional concreta.

En la Universidad Técnica Federico Santa María, la Dirección de Transformación Digital (DTD) desarrolló SAT-E como respuesta a ese desafío. El punto de partida fue una restricción práctica: las unidades de acompañamiento no requieren un puntaje continuo de riesgo, sino listas de tamaño manejable, disponibles en momentos determinados del calendario académico y estables en su interpretación entre carreras muy distintas. Un estudiante de Ingeniería Civil de seis años y uno de Técnico Universitario no comparten ni el perfil de ingreso ni la estructura curricular: tratarlos con un mismo modelo y un mismo umbral produce listas desbalanceadas e inoperables.

SAT-E aborda esa restricción con tres decisiones de diseño que constituyen el aporte de este trabajo: emitir tres alertas secuenciales sobre la misma cohorte, cada una anclada a un hito del calendario académico y a la información disponible en ese momento; entrenar los modelos por tipo de carrera; y fijar los umbrales de riesgo por optimización numérica sujeta a restricciones operacionales explícitas. El artículo describe la arquitectura del sistema, reporta el desempeño de los modelos entrenados y validados con las cohortes 2023 a 2025, presenta las alertas emitidas para la cohorte 2026 y discute lo que la evidencia interna permite y no permite afirmar.

DESARROLLO

1. Diseño del sistema: tres alertas sobre una misma cohorte

La Figura 1 resume el flujo de datos y los tres momentos de decisión en que SAT-E organiza el primer año.

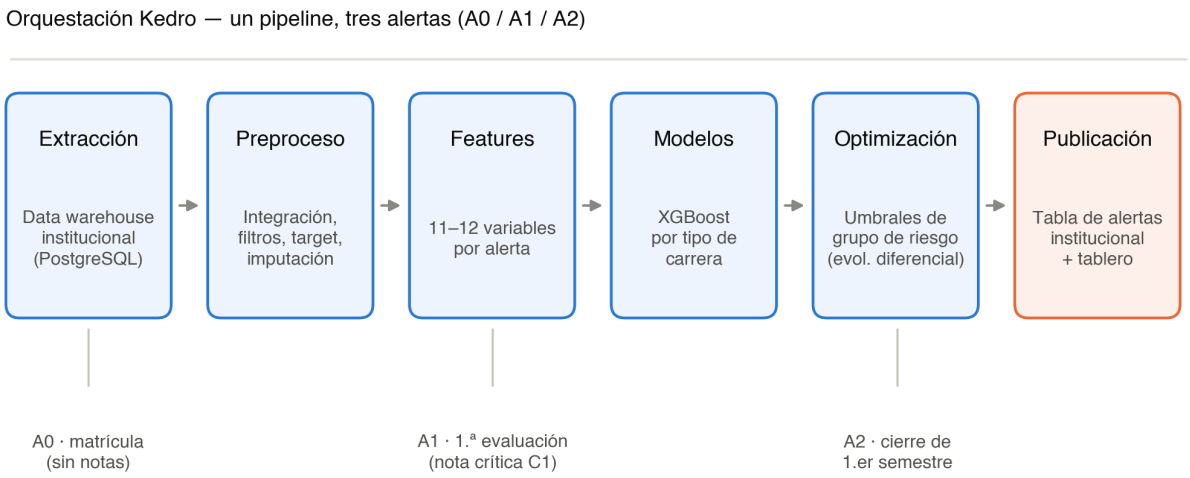


Figura 1. Arquitectura del pipeline SAT-E y momentos de emisión de cada alerta
Fuente: elaboración propia

Alerta 0 (A0) se emite al momento de la matrícula, antes de que exista cualquier registro de

desempeño universitario. Solo dispone de antecedentes de admisión: puntajes de la prueba de acceso, notas de enseñanza media, caracterización socioeconómica y datos de procedencia. Predice la reprobación de la asignatura crítica de matemática del primer semestre.

Alerta 1 (A1) se emite tras la primera evaluación (certamen C1) y agrega una única variable: la nota crítica, definida como la peor calificación C1 entre las asignaturas del área de matemática, excluyendo laboratorios y talleres. Predice el mismo evento que A0.

Alerta 2 (A2) se emite al cierre del primer semestre y cambia el objeto de predicción: su variable objetivo ya no es el desempeño en una asignatura, sino la no retención al año siguiente, tomada del registro institucional de cohortes de ingreso. Agrega la razón de créditos aprobados sobre créditos inscritos del primer semestre.

La progresión es deliberada: A0 maximiza la anticipación y minimiza la información, y A2 lo inverso. El sistema no elige entre ambas, sino que las emite en secuencia, de modo que el acompañamiento comience temprano con una lista amplia y se refine a medida que la trayectoria se hace observable.

2. Fuentes de datos y construcción del conjunto de entrenamiento

Todas las fuentes provienen del data warehouse institucional (PostgreSQL) y se consumen mediante consultas parametrizadas declaradas en el catálogo del proyecto. Se integran cinco tablas: la ficha consolidada del estudiante nuevo (antecedentes de admisión, socioeconómicos y curriculares), el libro de calificaciones por asignatura y evaluación, la nómina de notas del año objetivo, el registro de atenciones del centro de apoyo al aprendizaje y el registro de cohortes de ingreso, que aporta la marca de retención a un año.

El universo se restringe a estudiantes de ingreso regular desde la cohorte 2023: las cohortes 2023 a 2025 son el conjunto de entrenamiento y validación, y 2026 la cohorte de inferencia, con 5.100 estudiantes en 81 programas y cinco campus y sedes. Cada carrera se asigna a uno de cuatro tipos: Ingeniería de seis años (ing6), Ingeniería de cinco años (ing5), Ingeniería de base tecnológica (ibt) y Técnico Universitario (tu). La Tabla 1 resume la composición de los conjuntos por alerta.

Tabla 1. Composición de los conjuntos de datos y definición de la variable objetivo por alerta

	Alerta 0	**Alerta 1**	**Alerta 2**
Momento de emisión	Matrícula	Tras C1	Cierre 1.er semestre
Evento predicho	Reprobación asignatura crítica		No retención a un año
Registros de entrenamiento	12.737	12.737	14.155
Prevalencia del evento	43,3 %	43,3 %	19,3 %
Cohorte de inferencia (2026)	5.100	5.100	5.100
Variables predictoras	11	12	12

Fuente: elaboración propia a partir de los artefactos del pipeline SAT-E

La diferencia de registros de entrenamiento entre A0/A1 y A2 responde a que la variable objetivo de las dos primeras queda indefinida sin calificación válida en la asignatura crítica, mientras que la marca de retención existe para toda la cohorte cerrada.

3. Variables predictoras

El conjunto base, común a las tres alertas, contiene once variables: índice de vulnerabilidad, decil de ingreso del hogar, puntaje NEM, indicador de coincidencia entre la región del campus y la de residencia, puntajes de las pruebas de acceso de Competencia Lectora y Matemática 1, y variables indicadoras de sexo y de dependencia del establecimiento de origen. Los puntajes de acceso se

fijan en cero para los programas de Técnico Universitario, cuyo proceso de admisión no los exige, evitando imputar un valor que el modelo interpretaría como desempeño.

Los faltantes de las variables numéricas continuas se imputan con la mediana del tipo de carrera, no del total, para no arrastrar diferencias estructurales entre programas. Sobre esa base, A1 agrega la nota crítica C1 y A2 la razón de créditos aprobados: la diferencia entre alertas es de una sola variable en cada paso.

4. Modelos de predicción

Cada alerta entrena cuatro modelos independientes de gradient boosting sobre árboles, uno por tipo de carrera, utilizando la implementación XGBoost (Chen y Guestrin, 2016). La partición, estratificada por la variable objetivo dentro de cada tipo de carrera con 80 % para entrenamiento y 20 % para prueba, y el cálculo de métricas se realizan con scikit-learn (Pedregosa et al., 2011). La configuración base emplea 256 estimadores, tasa de aprendizaje de 0,05, profundidad máxima de 4, submuestreo de 0,8 por observación y por columna, regularización L2 unitaria y AUC como métrica. Sobre ella se aplican ajustes según el tamaño de cada subpoblación: ing6, el grupo más numeroso, admite mayor capacidad (profundidad 6 y 512 estimadores), mientras que ibt, el más pequeño, se restringe (profundidad 3, 128 estimadores y regularización reforzada) para contener el sobreajuste.

La evaluación reporta exactitud, precisión, exhaustividad, F1 y AUC-ROC sobre el conjunto de prueba, junto con matrices de confusión, curvas ROC, importancia de variables y valores SHAP (Lundberg y Lee, 2017), empleados para explicar casos individuales ante las unidades de acompañamiento.

5. De la probabilidad al grupo de riesgo

Una probabilidad continua no es un insumo operable para un equipo de tutorías. SAT-E la traduce a cuatro grupos ordenados — Sin Riesgo, Riesgo Bajo, Riesgo Medio y Riesgo Alto — mediante tres umbrales fijados por tipo de carrera y alerta. Dado $\tau = (\tau_1, \tau_2, \tau_3)$ con $0 = \tau_0 < \tau_1 < \tau_2 < \tau_3 < \tau_4 = 1$, el grupo del estudiante i con probabilidad estimada p_i es:

$$g_i = k \quad \text{si} \quad \tau_{k-1} < p_i \leq \tau_k, \qquad k = 1, \ldots, 4 \tag{1}$$

Los umbrales no se fijan por convención (por ejemplo, en cuartiles) sino resolviendo un problema de optimización. Sea $m_k(\tau)$ la mediana, dentro del grupo k, de una variable de contraste externa al modelo — Matemática 1 en A0, nota crítica C1 en A1 y razón de créditos aprobados en A2 — y $P(\tau)$ una suma de penalizaciones. La función objetivo minimizada es:

$$J(\tau) = -\sum_{k=1}^{3} |m_{k+1}(\tau) - m_k(\tau)| + P(\tau) \tag{2}$$

El primer término premia que los grupos se separen en una variable observable e interpretable por el equipo docente, y no solo en la probabilidad del modelo. El término $P(\tau)$ codifica las restricciones operacionales: tamaño mínimo por grupo, tamaño mínimo y participación máxima para Riesgo Medio, un tope a la participación de cualquier grupo y una penalización cuadrática sobre la desviación respecto de una distribución objetivo de tamaños relativos. Se resuelve con evolución diferencial (Storn y Price, 1997) en su implementación de SciPy (Virtanen et al., 2020), con semilla fija para garantizar reproducibilidad.

Este componente es el que hace usable al sistema: la unidad de acompañamiento fija de antemano

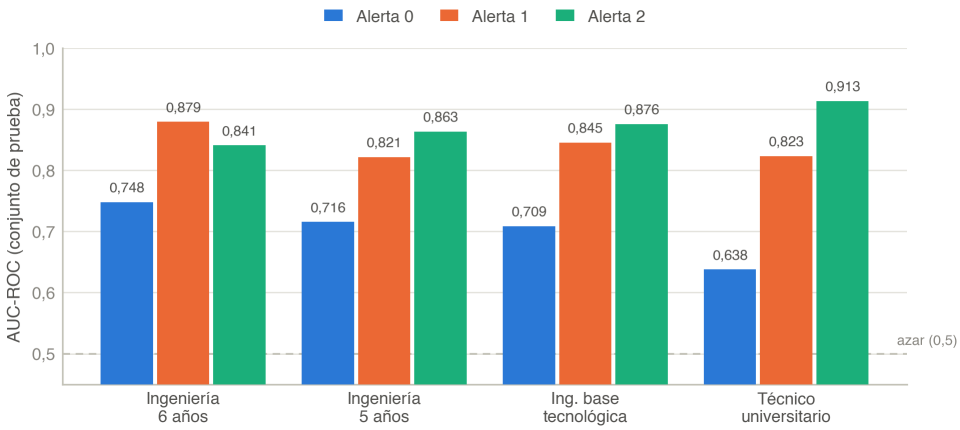


Figura 2. AUC-ROC por alerta y tipo de carrera sobre el conjunto de prueba
Fuente: elaboración propia

cuántos estudiantes puede atender y los grupos se construyen respetando esa capacidad.

6. Tratamiento explícito de la información faltante

Un estudiante para el cual la variable distintiva de la alerta no está disponible no recibe una predicción imputada: se le asigna la etiqueta *Sin información*, que se propaga hasta la salida final con probabilidad nula. La regla se activa cuando falta la nota crítica C1 en A1 y la razón de créditos aprobados en A2. Es una decisión conservadora — es preferible que la unidad de acompañamiento sepa que no hay información sobre un estudiante a que reciba una estimación construida sobre un valor imputado — y funciona además como indicador de calidad de los datos operacionales.

7. Implementación y operación

El sistema es un proyecto Kedro (Kedro Development Team, 2024) en Python, organizado en cinco pipelines encadenados — extracción, preprocesamiento, construcción de variables, modelos y optimización — que producen las tres alertas en una sola ejecución. La segmentación por alerta se resuelve mediante espacios de nombres y etiquetas, de modo que A0, A1 y A2 comparten el código de extracción y preprocesamiento y difieren solo en su configuración declarativa.

Toda la parametrización — consultas SQL, filtros de cohorte, definición del objetivo, listas de variables, hiperparámetros y restricciones de optimización — reside en archivos versionados, y los datos intermedios se persisten por capas, lo que permite reejecutar cualquier etapa de forma aislada y auditar el origen de cada alerta. El proyecto incluye pruebas automatizadas con un umbral de cobertura de 80 %, control de estilo e integración continua.

Las salidas se publican en la tabla studentaid.alerts_academic_risk del data warehouse, con una llave compuesta por estudiante, año de admisión, año y semestre de la alerta y tipo de alerta; la carga valida el esquema y verifica duplicados antes de escribir. Un tablero en Streamlit permite explorar métricas, curvas ROC, matrices de confusión, importancia de variables, valores SHAP y la composición de los grupos.

RESULTADOS

1. Desempeño predictivo

La Tabla 2 y la Figura 2 presentan el desempeño de los doce modelos sobre sus conjuntos de prueba.

Tabla 2. Desempeño de los modelos por alerta y tipo de carrera, conjunto de prueba

Alerta	Tipo de carrera	n	Exactitud	Precisión	Exhaust.	F1	AUC
A0	Ingeniería 6 años	1.225	0,682	0,585	0,596	0,590	0,748
	Ingeniería 5 años	373	0,660	0,682	0,665	0,674	0,716
	Ing. base tecnológica	197	0,645	0,590	0,697	0,639	0,709
	Técnico Universitario	754	0,594	0,556	0,591	0,573	0,638
A1	Ingeniería 6 años	1.175	0,806	0,737	0,754	0,746	0,879
	Ingeniería 5 años	343	0,761	0,766	0,791	0,778	0,821
	Ing. base tecnológica	172	0,750	0,711	0,821	0,762	0,845
	Técnico Universitario	630	0,754	0,741	0,724	0,732	0,823
A2	Ingeniería 6 años	1.311	0,862	0,475	0,550	0,509	0,841
	Ingeniería 5 años	415	0,860	0,618	0,618	0,618	0,863
	Ing. base tecnológica	213	0,817	0,462	0,686	0,552	0,876
	Técnico Universitario	894	0,861	0,739	0,823	0,779	0,913

Fuente: elaboración propia a partir de las métricas generadas por el pipeline SAT-E

El resultado central es el salto entre A0 y A1: el AUC-ROC ponderado por tamaño del conjunto de prueba pasa de 0,708 a 0,853 — un aumento de 0,145 producido por una sola variable, la nota del primer certamen de matemática — y la exactitud sube de 0,650 a 0,781. Ningún ajuste de hiperparámetros ni variable adicional de admisión produjo una ganancia comparable. La lectura institucional es directa: el mejor predictor del riesgo académico en primer año no está en el perfil de ingreso, sino en la primera respuesta observable del estudiante al régimen académico universitario.

A2 alcanza un AUC-ROC ponderado de 0,870 prediciendo un evento distinto y menos frecuente: la no retención, con prevalencia de 19,3 % frente al 43,3 % de la reprobación de la asignatura crítica. Ese desbalance explica el contraste entre su alta exactitud (0,858 ponderada) y su precisión más baja — en ing6, exactitud de 0,862 con precisión de 0,475 —. La asimetría es aceptable, porque contactar a un estudiante que no habría desertado cuesta mucho menos que omitir a uno que sí lo hará; aun así, obliga a comunicar los grupos como una priorización del acompañamiento y no como un pronóstico individual.

El patrón por tipo de carrera es heterogéneo pero estable: Técnico Universitario es el segmento donde A0 rinde peor (AUC 0,638, el único valor cercano a 0,6 del sistema) y donde A2 rinde mejor (0,913). Es coherente con el diseño, porque estos programas no exigen las pruebas de acceso — A0 opera allí con variables más pobres — mientras que su avance curricular resulta un discriminador especialmente informativo.

2. Variables determinantes

La Tabla 3 muestra la variable de mayor importancia relativa en cada modelo y confirma la interpretación anterior.

En A0 ninguna variable supera el 21 % de la importancia total y las primeras posiciones se reparten entre puntajes de acceso, NEM y caracterización socioeconómica: el modelo distribuye su capacidad predictiva porque ninguna señal domina. En A1 y A2 el patrón se invierte y la variable de trayectoria introducida en cada paso ocupa el primer lugar en los cuatro tipos de carrera, con importancias de hasta 0,394 (nota crítica C1) y 0,582 (razón de créditos aprobados), ambas en Técnico Universitario. Es el mismo hallazgo de las métricas, visto desde la estructura interna del modelo.

Tabla 3. Variable de mayor importancia relativa por alerta y tipo de carrera

Alerta	Tipo de carrera	Variable principal	Importancia
A0	Ingeniería 6 años	Puntaje Matemática 1	0,184
	Ingeniería 5 años	Puntaje Matemática 1	0,193
	Ing. base tecnológica	Dependencia del establecimiento	0,204
	Técnico Universitario	Puntaje NEM	0,198
A1	Ingeniería 6 años	Nota crítica C1	0,301
	Ingeniería 5 años	Nota crítica C1	0,228
	Ing. base tecnológica	Nota crítica C1	0,251
	Técnico Universitario	Nota crítica C1	0,394
A2	Ingeniería 6 años	Razón de créditos aprobados	0,268
	Ingeniería 5 años	Razón de créditos aprobados	0,344
	Ing. base tecnológica	Razón de créditos aprobados	0,293
	Técnico Universitario	Razón de créditos aprobados	0,582

Fuente: elaboración propia. La importancia corresponde a la ganancia relativa normalizada de XGBoost

3. Cobertura y composición de los grupos de riesgo

La Figura 3 presenta la composición de la cohorte 2026 en cada alerta y la cobertura efectiva de cada una.

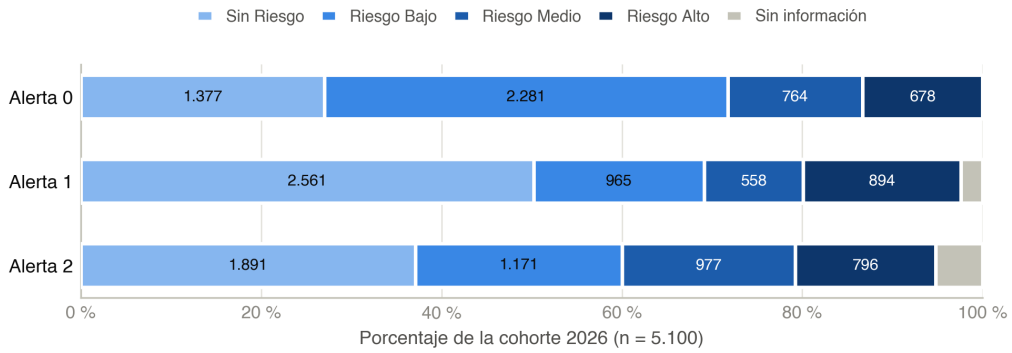


Figura 3. Distribución de la cohorte de admisión 2026 por grupo de riesgo y alerta
Fuente: elaboración propia

Las tres alertas cubren a los 5.100 estudiantes de la cohorte y en A0 la cobertura con inferencia es total, porque sus variables provienen del proceso de admisión. En A1 quedan 122 estudiantes (2,4 %) como *Sin información* y en A2 son 265 (5,2 %): la cobertura efectiva con predicción es de 97,6 % y 94,8 %.

La composición refleja el efecto de la optimización de umbrales. En A0 domina Riesgo Bajo (2.281 estudiantes, 44,7 %) y Riesgo Medio y Alto reúnen 1.442 (28,3 %). En A1 la distribución se concentra en Sin Riesgo (2.561, 50,2 %) y Riesgo Alto crece a 894 (17,5 %): con desempeño real observado, el modelo separa con más decisión. En A2, Riesgo Medio y Alto suman 1.773 (34,8 %) sobre la predicción de no retención.

4. Transición entre alertas

Disponer de dos alertas sobre la misma cohorte permite observar cómo se reconfigura el riesgo durante el semestre. La Figura 4 cruza el grupo asignado en A1 con el de A2 para los 5.100 estudiantes de la cohorte 2026.

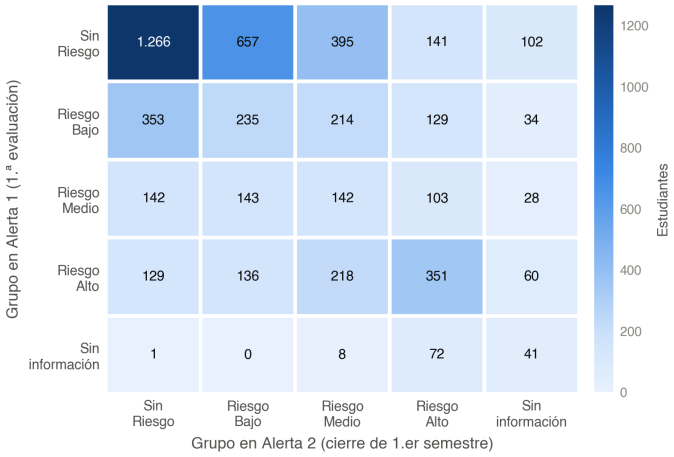


Figura 4. Transición de grupo de riesgo entre Alerta 1 y Alerta 2, cohorte 2026
Fuente: elaboración propia

Ordenando los grupos por severidad y asignando el nivel más bajo a *Sin información*, 2.035 estudiantes (39,9 %) permanecen en el mismo grupo, 1.720 (33,7 %) suben y 1.345 (26,4 %) bajan; las celdas más pobladas de la diagonal son Sin Riesgo en ambas alertas (1.266) y Riesgo Alto en ambas (351).

La implicación operativa es relevante: seis de cada diez estudiantes cambian de grupo entre la primera evaluación y el cierre del semestre, de modo que un sistema de alerta única — temprana o tardía — clasificaría erróneamente a una fracción sustantiva de la cohorte durante buena parte del año. A1 y A2 predicen eventos distintos, por lo que la transición debe leerse como un cambio en la prioridad de acompañamiento y no como la corrección de un pronóstico previo.

5. Alertas publicadas y calidad de los datos operacionales

La tabla institucional acumula 37.947 alertas sobre cuatro cohortes consecutivas: 8.667 en 2023 (4.568 de A1 y 4.099 de A2), 9.240 en 2024 (4.581 y 4.659), 9.840 en 2025 (4.920 y 4.920) y 10.200 en 2026 (5.100 y 5.100); desde 2025 ambas cubren la cohorte de ingreso completa. La etiqueta *Sin información* resultó ser, además de una salvaguarda metodológica, un instrumento de diagnóstico de la calidad de los datos. En los 265 casos de A2 de la cohorte 2026, el 100 % se explica por la ausencia de la razón de créditos aprobados del primer semestre; ninguno corresponde a razón igual a cero, que sí recibe inferencia. Al cruzarlos con la nómina de calificaciones, 216 (81,5 %) tienen nota C1 registrada, 29 no aparecen en la nómina del período, 10 aparecen sin C1 y 10 no figuran en ninguna nómina revisada. Para cuatro de cada cinco el problema no es la falta de actividad académica registrada sino la del cómputo de créditos en la fuente; se concentran en Técnico Universitario (100) e Ingeniería de seis años (80). El hallazgo redirigió parte del trabajo de la DTD desde el modelamiento hacia la corrección del registro curricular aguas arriba, con efecto directo sobre la cobertura de la alerta.

CONCLUSIONES

SAT-E muestra que es posible construir un sistema de alerta temprana operativo sobre la infraestructura de datos que la institución ya posee, sin instrumentos adicionales de recolección y con una arquitectura reproducible y auditable. Los aportes de la experiencia son cuatro.

El primero es empírico y es el resultado más transferible del trabajo: la información de trayectoria temprana supera con amplitud a los antecedentes de ingreso como predictor del riesgo. Incorporar

la nota del primer certamen de matemática eleva el AUC-ROC de 0,708 a 0,853, y el avance curricular del primer semestre permite predecir la no retención con un AUC-ROC de 0,870. Para una institución que evalúe implementar un sistema de alerta temprana, esto sugiere priorizar la disponibilidad oportuna y confiable de las calificaciones parciales por sobre la sofisticación del modelo.

El segundo es de diseño: la secuencia de tres alertas resuelve el dilema entre anticipación y precisión sin sacrificar ninguna de las dos, y la evidencia de transición lo respalda, ya que seis de cada diez estudiantes cambian de grupo entre la primera evaluación y el cierre del semestre. El tercero es operativo: la optimización de umbrales con restricciones explícitas de tamaño hace que las listas de riesgo sean compatibles con la capacidad real de atención de las unidades de acompañamiento, y la segmentación por tipo de carrera evita listas desbalanceadas entre programas con perfiles de ingreso muy distintos. El cuarto es un subproducto no previsto: la etiqueta *Sin información* convirtió al sistema en un mecanismo de auditoría de la calidad de los datos operacionales, identificando los 265 estudiantes de la cohorte 2026 con registro de avance curricular incompleto y el punto exacto del proceso donde se origina la falta.

Las limitaciones son igualmente claras. La principal es que este trabajo reporta desempeño predictivo, no efectividad de la intervención: no se ha evaluado si los estudiantes alertados y acompañados presentan mejores tasas de retención que sus pares, y sin ese contraste el sistema demuestra capacidad de identificación pero no impacto. La validación, además, es interna mediante partición aleatoria dentro de cada cohorte; una validación temporal estricta, entrenando en cohortes anteriores y evaluando en posteriores, es la prueba que corresponde a un sistema de uso prospectivo. A ello se suma el desempeño modesto de A0 en el segmento de Técnico Universitario (AUC 0,638), que aconseja comunicar sus resultados con cautela en esos programas, y el uso de variables socioeconómicas y de procedencia, que exige un monitoreo explícito de equidad para asegurar que la priorización del acompañamiento no reproduzca desventajas de origen.

Las proyecciones se ordenan en función de esas limitaciones. En el corto plazo, cerrar el ciclo de retroalimentación con las unidades de acompañamiento — registrando qué estudiantes fueron contactados y con qué intervención — para habilitar la evaluación de impacto, e incorporar al pipeline el monitoreo de drift entre cohortes y de equidad por subgrupo. En el mediano plazo, extender la secuencia más allá del primer año, integrar las salidas en los sistemas que ya usan los equipos de tutorías y evaluar el reentrenamiento periódico a medida que se cierren nuevas cohortes.

Para evaluar el impacto del acompañamiento se propone un diseño en dos etapas. Primero, un ensayo controlado aleatorio con lista de espera: dentro de cada tipo de carrera y grupo de riesgo (Medio y Alto), la capacidad limitada de las unidades de acompañamiento permite asignar al azar quiénes reciben apoyo durante el primer semestre y quiénes lo reciben de forma diferida, sin privar de atención a estudiantes alertados. Segundo, cuando la aleatorización no sea viable, un diseño cuasiexperimental, como una regresión discontinua en torno a los umbrales de grupo o una diferencia en diferencias entre carreras o cohortes con incorporación escalonada. En ambos casos, los desenlaces serían la aprobación de la asignatura crítica, la razón de créditos aprobados y la retención a un año, comparados con los de estudiantes del mismo grupo de riesgo sin acompañamiento, con resguardos éticos y revisión por un comité.

AGRADECIMIENTOS

Los autores agradecen a la Dirección de Transformación Digital de la Universidad Técnica Federico Santa María por el respaldo institucional al desarrollo de SAT-E, y a las unidades de acompaña-

miento estudiantil, cuya retroalimentación sobre la operación real de las alertas orientó decisiones centrales del diseño, en particular las restricciones de tamaño de los grupos de riesgo y el tratamiento de los casos sin información.

REFERENCIAS

Arnold, K. E., y Pistilli, M. D. (2012). Course Signals at Purdue: Using learning analytics to increase student success. *Proceedings of the 2nd International Conference on Learning Analytics and Knowledge*, 267–270. https://doi.org/10.1145/2330601.2330666

Baker, R. S., e Inventado, P. S. (2014). Educational data mining and learning analytics. En J. A. Larusson y B. White (Eds.), *Learning analytics: From research to practice* (pp. 61–75). Springer. https://doi.org/10.1007/978-1-4614-3305-7_4

Chen, T., y Guestrin, C. (2016). XGBoost: A scalable tree boosting system. *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 785–794. https://doi.org/10.1145/2939672.2939785

Jayaprakash, S. M., Moody, E. W., Lauría, E. J. M., Regan, J. R., y Baron, J. D. (2014). Early alert of academically at-risk students: An open source analytics initiative. *Journal of Learning Analytics*, *1*(1), 6–47. https://doi.org/10.18608/jla.2014.11.3

Kedro Development Team. (2024). *Kedro: A Python framework for creating reproducible, maintainable and modular data science code* [Software]. https://kedro.org

Lundberg, S. M., y Lee, S.-I. (2017). A unified approach to interpreting model predictions. *Advances in Neural Information Processing Systems*, *30*, 4765–4774.

Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., y Duchesnay, É. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, *12*, 2825–2830.

Siemens, G., y Long, P. (2011). Penetrating the fog: Analytics in learning and education. *EDUCAUSE Review*, *46*(5), 30–40.

Storn, R., y Price, K. (1997). Differential evolution — A simple and efficient heuristic for global optimization over continuous spaces. *Journal of Global Optimization*, *11*(4), 341–359. https://doi.org/10.1023/A:1008202821328

Tinto, V. (1975). Dropout from higher education: A theoretical synthesis of recent research. *Review of Educational Research*, *45*(1), 89–125. https://doi.org/10.3102/00346543045001089

Tinto, V. (1993). *Leaving college: Rethinking the causes and cures of student attrition* (2.ª ed.). University of Chicago Press.

Virtanen, P., Gommers, R., Oliphant, T. E., Haberland, M., Reddy, T., Cournapeau, D., Burovski, E., Peterson, P., Weckesser, W., Bright, J., van der Walt, S. J., Brett, M., Wilson, J., Millman, K. J., Mayorov, N., Nelson, A. R. J., Jones, E., Kern, R., Larson, E., … SciPy 1.0 Contributors. (2020). SciPy 1.0: Fundamental algorithms for scientific computing in Python. *Nature Methods*, *17*(3), 261–272. https://doi.org/10.1038/s41592-019-0686-2