
SCIPS: Single-Shot Photometric Stereo from a Snapshot Compressed Multispectral Image


Una exposición, una medición 2D, un mapa de normales

*Yunhao Li · Yanan Hu · Xiaodong Wang · Yuze Yang · Ziyi Meng · Xin Yuan · Peidong Liu
Zhejiang University · Westlake University · ICIP 2026*

Presentación de paper — Francisco Alfaro Medina
Doctorado en Ingeniería Electrónica · Universidad Técnica Federico Santa María

La promesa y el precio del estéreo fotométrico

- El **estéreo fotométrico** (Woodham, 1980) recupera normales de superficie a partir de imágenes bajo iluminación variable — sigue siendo el estándar de oro para el detalle geométrico *fino*.
- El costo: **una imagen por cada fuente de luz**, capturadas de forma secuencial.
- Adquisición lenta, mucho almacenamiento, nada de sujetos en movimiento.
- SCIPS hace una pregunta directa: ¿se puede lograr con **una sola exposición de 10–20 ms y un único cuadro 2D**?



El problema

Todo camino hacia el PS de una captura tiene
un cuello de botella

Tres caminos, tres cuellos de botella

Enfoque	Cómo separa las luces	Cuello de botella
PS convencional [1,2]	Tiempo — una luz blanca por cuadro	Captura secuencial: lenta y costosa en almacenamiento
PS multispectral RGB [3,4]	Longitud de onda — 3 canales del sensor	Solo ~3 fuentes de luz efectivas; los filtros de color o las luces alternadas reintroducen la captura secuencial
PS hiperespectral	Longitud de onda — muchos canales	Las cámaras hiperespectrales son caras y poco prácticas de desplegar

La brecha. El multiplexado espectral es la idea correcta — codificar la dirección de iluminación en la longitud de onda y encender todas las luces a la vez — pero un sensor RGB estándar no tiene canales suficientes, y una cámara hiperespectral no es una respuesta práctica.



Imagen compresiva de una captura (SCI): el modelo directo

Un cubo multispectral $I \in \mathbb{R}^{H \times W \times N_\lambda}$ es **codificado**, **cizallado** y **colapsado** sobre un único sensor 2D:

$$I' = I \odot M$$

$$I''(x, y, n_\lambda) = I'(x + d(\lambda_{n_\lambda} - \lambda_c), y, n_\lambda)$$

$$Y = \sum_{n_\lambda=1}^{N_\lambda} I''(:, :, n_\lambda) + Z$$

- Con $d = 1$, la medición es $\frac{W \cdot N_\lambda}{W + N_\lambda - 1}$ veces más eficiente en memoria que el cubo.
- Para $W = 1024$, $N_\lambda = 12 \approx \mathbf{11,9 \times \text{de compresión}}$, sobre un sensor CMOS estándar.
- El precio: recuperar I a partir de Y es un problema **severamente mal planteado**.

M : máscara de apertura codificada · d : paso de dispersión · Z : ruido del sensor · Y : el único cuadro capturado

Por qué falla el pipeline obvio

Línea base en dos etapas

medición SCI

↓ *reconstrucción SCI* (MST, SSR)

cubo multiespectral

↓ *estéreo fotométrico* (SDM-UniPS, NeuralMPS, MultispectralPS)

mapa de normales

- Los errores de la etapa 1 **se propagan y se acumulan** en la etapa 2.
- Ambas etapas son redes preentrenadas → **generalización limitada**, sobre todo hacia datos SCI reales.
- La etapa 1 optimiza un objetivo *espectral*, ciego a la tarea *geométrica* que viene después.

SCIPS: una sola etapa

medición SCI

↓ *renderizado inverso neuronal con el modelo SCI dentro del lazo*

normales + albedo + iluminación

- El cubo **nunca se reconstruye**: es una cantidad intermedia dentro de un renderizador diferenciable.
- **Optimización por escena** en tiempo de inferencia → sin brecha de dominio entre entrenamiento y test.
- Un solo objetivo: consistencia fotométrica con la medición efectivamente capturada.

El método

Meter la física de la cámara dentro de la optimización

SCIPS en tres ideas

1 • Renderizado inverso neuronal

Dos MLP mapean coordenadas de píxel (x, y) a la normal de superficie n y al albedo difuso y especular ρ_d, ρ_s .

Sin predicción feed-forward: la representación de la escena se **optimiza por objeto**, y eso es lo que la hace robusta entre escenas.

2 • Formación SCI explícita

El cubo renderizado se hace pasar por el modelo *real* de máscara y cizalle de las Ec. (1)–(3) para sintetizar una medición.

Como ese modelo es diferenciable, la pérdida se calcula **donde realmente viven los datos**: en el espacio de medición.


3 • Iluminación no calibrada

Un módulo CNN de estimación de luz inicializa l_i, l_d y se **ajusta de forma conjunta** con la geometría.

Sin paso de calibración lumínica ni direcciones de luz conocidas — un requisito práctico para un montaje desplegable.

Las tres están gobernadas por una **única pérdida fotométrica** contra un solo cuadro capturado. En todo el pipeline no hay supervisión con normales de referencia.

El framework, de punta a punta



Rendering: de coordenadas a imágenes espectrales

Cámara ortográfica, dirección de vista fija en $v = [0, 0, 1]^\top$.
Cada canal espectral ve el objeto bajo **una** luz direccional:

$$\hat{I} = l_i \rho(n, l_d) \max(n^\top l_d, 0)$$

La BRDF se separa en componente difusa y especular,
 $\rho(n, l_d) = \rho_d + \rho_s(n, l_d)$ — de modo que el modelo **no** queda restringido a superficies lambertianas:

[Math Processing Error]

Los dos MLP sobre coordenadas

$$n = \text{MLP}_{\text{normal}}(x, y)$$

$$\{\rho_d, \rho_s\} = \text{MLP}_{\text{albedo}}(x, y)$$

- 8 capas totalmente conectadas, 256 canales cada una
- El MLP de albedo agrega una cabeza de predicción de 128 canales
- Las entradas llevan **codificación posicional** — eso es lo que permite a una red sobre coordenadas representar detalle superficial de alta frecuencia
- Módulo de luz adaptado de Li & Li [20]

Cerrando el lazo: la pérdida fotométrica

[Math Processing Error]

Qué dice la ecuación

- Renderizar el cubo I , modularlo con la **máscara real** M , cizallarlo con T y sumar sobre la longitud de onda.
- Comparar contra el **único cuadro capturado** Y .
- Una sola pérdida escalar actualiza conjuntamente n, ρ_d, ρ_s, l_i y l_d .

Cuánto cuesta


- Adam, tasa de aprendizaje inicial 5×10^{-4}
- 10K–20K iteraciones, una sola NVIDIA RTX 4090
- **10–15 minutos por objeto** (dataset sintético)
- Tiempo de captura: una sola exposición de **10–20 ms**

La optimización en tiempo de inferencia suele ser una desventaja. Acá es justamente el punto: el modelo se ajusta a *esta* medición de *esta* cámara, así que no hay brecha de dominio entre los datos de entrenamiento y el montaje SCI real.

La evidencia

Benchmarks sintéticos y un prototipo real

Datasets: sintético y un prototipo físico



Sintético — renderizado en Blender

- 10 objetos: Ball, Bear, Bird, Bunny, Cat, Cabbage, Fish, Moai, Pot, Pumpkin
- $N_\lambda = 12$ canales, resolución 612×512
- Blender solo renderiza RGB, así que cada luz monocromática se renderiza por separado y se promedia por banda

Real — un sistema SCI-MPS construido para esto

- Apertura codificada + dispersor óptico + sistema de lentes + CMOS
- 12 LED de banda angosta, **460–665 nm**, resolución 1024×1024
- Geometría escaneada con un Shining3D EinScan Pro 2X Plus V2

! Limitación del dataset real

La ausencia de marcadores de calibración y la adquisición por separado implican que los datos reales **no tienen ground truth alineado a nivel de píxel** — los resultados reales son solo cualitativos.

Resultados cuantitativos — error angular medio en grados (menor es mejor)

Método	Ball	Bunny	Fish	Moai	Pumpkin	Promedio
MST [6] + MultispectralPS [4]	2.40	13.76	18.40	16.45	9.41	11.63
MST [6] + NeuralMPS [3]	9.82	14.53	15.82	7.85	5.51	10.62
MST [6] + SDM-UniPS [18]	2.42	7.18	12.81	5.30	13.35	7.60
SSR [7] + MultispectralPS [4]	2.21	13.64	18.16	17.18	9.98	11.81
SSR [7] + NeuralMPS [3]	9.98	11.89	14.20	10.48	5.08	10.73
SSR [7] + SDM-UniPS [18]	2.57	6.97	13.70	6.18	12.99	7.90
SCIPS (propuesto)	0.55	4.96	9.73	2.54	1.12	4.39

4,39°

MAE promedio sobre los 10 objetos

−42%


frente a la mejor línea base de dos etapas
(7,60°)

8,03° / 0,09

MAE de dirección de luz / error de intensidad

Comparación cualitativa


MST+SDM-UniPS



Ours



Reference Normal



Ablación: qué aporta cada componente

Configuración	MAE ↓
Propuesto sin LEM (módulo de estimación de luz)	8.97
Propuesto sin LO (optimización de luz)	7.04
Propuesto (completo)	4.39

Quitar el módulo de estimación de luz cuesta **+4,6°**: más que duplica el error. La iluminación no es un detalle de este pipeline, es la mitad del problema.

- **Sin LEM**, la iluminación parte de una inicialización pobre y la optimización conjunta no tiene un punto confiable desde el cual descender.
- **Sin LO**, la iluminación se estima una vez y se congela: los errores en l_i, l_d se absorben en las normales, la falla clásica del PS no calibrado.
- Ambos son **complementarios**: una buena inicialización *y* la libertad de refinarla.
- Notar que **solo sin LO (7,04°) ya supera a todas las líneas base de dos etapas** — la formulación de una sola etapa es la ganancia, y el refinamiento de luz abre la brecha.

Conclusiones

Lo que el paper establece

- Se pueden recuperar normales de superficie desde una **única medición 2D comprimida**, sin reconstruir el cubo.
- Poner el **modelo directo de SCI dentro** de un renderizador diferenciable supera al esquema reconstruir-y-después-estimar: **4,39°** contra **7,60°** de MAE.
- La optimización por escena junto a la estimación conjunta de luz elimina de una vez el paso de **calibración** y la **brecha de dominio**.
- Un prototipo funcional y dos datasets nuevos hacen que la afirmación sea verificable sobre óptica real.

Lo que queda abierto

- **10–15 min por objeto**: la captura es rápida, la reconstrucción no. El renderizado inverso en tiempo real es el próximo objetivo evidente.
- **Sin evaluación cuantitativa en datos reales** — un ground truth registrado zanjara esa afirmación.
- Un objeto, una vista, cámara ortográfica; sin interreflexiones ni sombras proyectadas más allá del término $\max(\cdot, 0)$.
- ¿Cuánto se degrada al bajar N_λ , o cuando la máscara se aparta de la calibrada?

Gracias

¿Preguntas?

SCIPS: Single-Shot Photometric Stereo from a Snapshot Compressed Multispectral Image
Li, Hu, Wang, Yang, Meng, Yuan & Liu · ICIP 2026 · DOI 10.1109/ICIP61757.2026.11630570

Francisco Alfaro Medina · Universidad Técnica Federico Santa María
<https://github.com/fralfaro/talks>